

TP1 - Modelado Estadístico

Austin Animal Center

Emiliano Torres y Federico Leonardis Ayala

2026-06-27

El Austin Animal Center es el refugio municipal más grande de Estados Unidos. Analizar sus registros nos puede ayudar a identificar qué perfil de animal tiene mayores chances de adopción, que tasas de adopción tiene el refugio y que tan rápido se adoptan los animales según sus características (y en comparación a otros posibles desenlaces).

1. Exploración inicial

El dataset del refugio contiene **137 806 animales** (77 629 perros y 60 177 gatos), sin valores faltantes.

Table 1: Resumen de las variables principales.

Variable	Valor
Edad (mediana, años)	1
Edad (máx, años)	24
Estadía (mediana, días)	6.9
Estadía (máx, días)	364.9
Esterilizados (%)	20.6
Machos (%)	51.2




Figure 1: Distribución de los cuatro desenlaces posibles.

La Figura 1 muestra que la adopción es el desenlace más frecuente (53% de los casos), seguida por transferencia (28,6%). La muerte es el menos frecuente (3,7%).




Figure 2: Izquierda: distribución de la edad al ingreso. Derecha: composición de desenlaces por tipo de animal.

La Figura 2 muestra que la distribución de edad es marcadamente asimétrica: la mayoría de los animales ingresa en sus primeros meses de vida. Los desenlaces difieren notablemente entre especies: las devoluciones son casi exclusivas de perros (23,1% vs 4% en gatos), mientras que las transferencias tienen más peso relativo en felinos (35,8% vs 23%).




Figure 3: Izquierda: tiempo de estadía por desenlace (escala logarítmica). Derecha: correlaciones de Pearson entre variables numéricas y binarias del dataset (para variables 0/1, la correlación de Pearson coincide con el coeficiente phi).

En la Figura 3, el tiempo varía según el desenlace: las devoluciones son las más rápidas (mediana = 1.7 días), mientras que las adopciones demoran más y con mayor dispersión (mediana = 14.2 días; el 25% supera los 43 días).

La correlación más fuerte es entre esterilización y edad ($r = 0.52$): los cachorros ingresan predominantemente sin esterilizar, lo cual es esperable dado que la esterilización se realiza a partir de cierta edad. El resto de las correlaciones son débiles, lo que indica que las variables aportan información relativamente independiente al modelo.

2. Estimación de la tasa de adopción por raza

Queremos estimar la tasa de adopción de cada raza. La estimación “obvia” es la tasa cruda: adoptados sobre total. Estudiamos si conviene usar esa tasa o el estimador de Empirical Bayes.

Tasa verdadera por raza

Definimos la tasa “verdadera” de cada raza como su proporción de adopciones calculada sobre todos los animales del dataset. Para que esta referencia sea confiable, nos quedamos con las razas que tienen al menos 100 animales, resultando en **120 razas** (54.4% perros, 45.6% gatos el subset está balanceado entre especies, por lo que las conclusiones aplican a ambas).




Figure 4: Distribución de la tasa verdadera de adopción entre las 120 razas con al menos 100 animales.

La Figura 4 muestra que la distribución de tasas verdaderas es aproximadamente unimodal y concentrada entre 40% y 70%, con media 49.2%. Esta forma justifica el uso de una distribución Beta como prior.

Simulación y comparación de estimadores

Para simular la situación de poca data, tomamos una muestra aleatoria de $m = 15$ animales por raza y calculamos la **tasa cruda** (adoptados / m). Elegimos $m = 15$ como un escenario de muestra muy chica donde la estimación cruda es ruidosa pero el shrinkage tiene margen para mejorarla.

Ajustamos una prior $\text{Beta}(\alpha_0, \beta_0)$ sobre las tasas muestrales por máxima verosimilitud (MLE), obteniendo $\alpha_0 = 2.13$ y $\beta_0 = 2.2$ (media: 49.2%). El estimador de Empirical Bayes combina prior y datos:

$$\hat{p}_i^{EB} = \frac{\alpha_0 + \text{adoptados}_i}{\alpha_0 + \beta_0 + m}$$

Este estimador aplica *shrinkage*: encoge las tasas extremas hacia la media de la prior. Como m es fijo para todas las razas, el shrinkage es uniforme a diferencia del caso clásico donde grupos con menos observaciones serían encogidos más fuertemente.




Figure 5: Estimaciones vs tasa verdadera para ambos estimadores (línea punteada = estimación perfecta). El EB reduce visiblemente la dispersión alrededor de la diagonal.

La Figura 5 muestra que el estimador EB reduce el ECM de 0.015 a 0.0101, una mejora del 32.6%. La dispersión alrededor de la diagonal se reduce notablemente: el estimador crudo produce errores grandes en ambas direcciones, mientras que el EB mantiene las estimaciones mucho más cerca de la identidad.




Figure 6: Mecanismo de shrinkage: el estimador EB encoge todas las tasas crudas hacia la media de la prior (línea punteada). Puntos por encima de la diagonal fueron corregidos hacia arriba; por debajo, hacia abajo.

En la Figura 6, todos los puntos se acercan a la línea horizontal de la media de la prior (49.2%): las razas con tasa cruda alta son corregidas hacia abajo y las de tasa cruda baja hacia arriba. Como m es fijo para todas las razas, el shrinkage es uniforme a diferencia del caso clásico donde grupos con menos observaciones serían encogidos más fuertemente.

3. Modelando los desenlaces

Nos interesa estudiar los posibles desenlaces de los animales del refugio. En lugar de ajustar una regresión logística por desenlace lo cual ignoraría que las cuatro probabilidades deben sumar 1, elegimos el modelo multinomial que las estima en conjunto.

El modelo multinomial permite estimar las probabilidades de K resultados distintos. Definimos P_i como la probabilidad del i -ésimo evento. Como estas probabilidades suman 1, no pueden modelarse de forma completamente independiente: conocer $K - 1$ de ellas determina la restante.

Por eso se elige una categoría de referencia (en nuestro caso, Adopción) y se modela el cociente entre cada categoría y la referencia:

$$\log\left(\frac{P_i}{P_{\text{Adopción}}}\right) = \beta_i^\top \bar{x}$$

La función logaritmo actúa como función de link: transforma un cociente positivo en un valor real. De forma equivalente:

$$\frac{P_i}{P_{\text{Adopción}}} = \exp(\beta_i^\top \bar{x})$$

Cada categoría tiene sus propios coeficientes, de modo que una variable puede tener efectos distintos según qué desenlace se compare contra la adopción. Al exponenciar el coeficiente obtenemos el odds ratio (razón de ventajas) del desenlace i frente a la adopción. Un $\exp(\beta) = 2$ para una variable significa que, al aumentar esta en una unidad, la ventaja relativa del desenlace i frente a la adopción se duplica (no que su probabilidad absoluta lo haga).

Los scores así obtenidos se normalizan vía softmax para obtener probabilidades válidas que sumen 1:

$$P_K = \frac{1}{1 + \sum_{j=1}^{K-1} \exp(\beta_j^\top \bar{x})}, \quad P_i = \frac{\exp(\beta_i^\top \bar{x})}{1 + \sum_{j=1}^{K-1} \exp(\beta_j^\top \bar{x})}$$

Table 2: Odds ratios $\exp(\beta)$ del modelo multinomial (categoría de referencia: Adopción). Valores > 1 indican que aumentar la variable favorece al desenlace i por encima de la adopción; valores < 1 indican lo contrario.

Desenlace	Intercepto	Edad (años)	Perro	Esterilizado	Sexo (macho)
Devolucion	0.031	1.181	5.479	3.499	1.315
Transferencia	0.612	1.084	0.653	0.799	0.998
Muerte	0.055	1.275	0.493	0.685	1.295

Edad: el odds ratio es mayor que 1 para los tres desenlaces no-adopción, especialmente para Muerte ($\exp(\beta) = 1.275$): por cada año adicional, las chances relativas de morir en el refugio frente a ser adoptado aumentan un 27.5%. La edad juega en contra de la adopción.

Perro: ser perro multiplica por 5.48 las chances de devolución vs adopción (razonable, ya que la devolución implica tener dueño previo, fenómeno casi exclusivo de los perros). En cambio, ser perro *reduce* las chances de muerte ($\exp(\beta) = 0.493$): los perros tienen más chances relativas de adopción que los gatos.

Sexo: los coeficientes de **Sexo (macho)** son positivos en casi todos los desenlaces pero pequeños. Ser macho inclina levemente la balanza hacia cualquier salida que no sea la adopción.

4. ¿Qué tan rápido se adoptan los animales?

Para estudiar esto haremos un análisis de supervivencia. El evento de interés es la adopción; cualquier otro desenlace (transferencia, devolución, muerte) se trata como **censura**: sabemos que el animal estuvo en el refugio hasta ese momento sin ser adoptado, pero no observamos qué hubiera pasado después.

Definimos T como el tiempo hasta la adopción y $\hat{\lambda}_j = \# \text{adoptados}_j / \# \text{en_riesgo}_j$ como la tasa de adopción en el intervalo j entre quienes aún no fueron adoptados. La función de supervivencia se estima como el producto acumulado:

$$\hat{S}(t_j) = \prod_{t=1}^j (1 - \hat{\lambda}_t)$$

y la probabilidad acumulada de adopción es $1 - \hat{S}(t)$.




Figure 7: Izquierda: curva de Kaplan-Meier para la adopción (resto censurado). Derecha: probabilidades acumuladas en días clave.

La Figura 7 muestra que la probabilidad de adopción crece rápidamente en los primeros 30 días (56%), desacelera a los 90 días (89%) y casi satura a los 180 días (97%). Esto sugiere que las intervenciones tempranas tienen el mayor impacto potencial.

Para identificar qué variables aceleran o retrasan la adopción, ajustamos un modelo de Cox:

$$\lambda_i(t | x) = h_0(t) e^{\beta^\top x}$$

donde $h_0(t)$ es el hazard base y $e^\beta > 1$ implica mayor tasa de adopción (adopción más rápida).

Table 3: Modelo de Cox para tiempo hasta adopción. $\exp(\beta) > 1$ implica adopción más rápida.

Variable	$\exp(\beta)$	Est. z	p-valor
Edad (años)	0.9083	-43.8667	<1e-10
Perro (vs gato)	1.3895	42.3429	<1e-10
Esterilizado	1.0893	7.0749	<1e-10
Sexo (macho)	0.9471	-7.3276	<1e-10

Todos los coeficientes son estadísticamente significativos ($p < 0.001$). **Ser perro** es el factor que más acelera la adopción ($\exp(\beta) = 1.39$): los perros son adoptados un 39% más rápido que los gatos en cada momento del tiempo. **La edad** es el principal freno ($\exp(\beta) = 0.908$): cada año adicional reduce la tasa de adopción instantánea un 9.2%. **La esterilización** tiene un efecto positivo pero pequeño ($\exp(\beta) = 1.089$).

Conclusiones

El análisis permite trazar un perfil claro del animal con mayores chances de adopción en el Austin Animal Center: **perro joven**. La edad es el factor más perjudicial en múltiples frentes (aumenta las chances de muerte relativas a la adopción (Inciso 3) y retrasa el tiempo hasta ser adoptado (Inciso 4)). La esterilización ayuda, aunque su efecto es modesto. El Empirical Bayes demostró ser una herramienta robusta para estimar tasas con poca data, reduciendo el ECM en un 32.6% respecto al estimador crudo. Finalmente, el modelo de supervivencia revela que el 56% de las adopciones ocurren en los primeros 30 días, lo que sugiere que la difusión temprana de los animales tendría el mayor impacto en las tasas de adopción.